

Master Thesis

Fluid 4.0-Compliant Framework for Digital Representation and Graph-Based Neural Modeling

**Submitted in partial fulfillment of the requirements for the
degree of Master of Science (M.Sc.)**

Program: Advanced Precision Engineering (APE)
Faculty of Engineering and Technology
Hochschule Furtwangen

Presented by:

Manuel Alberto Caipo Ccoa
Matriculation Number: 286577

1st Supervisor: Dr. Maximilian Dommermuth
2nd Supervisor: Prof. Dr. Jörn Kretschmer

Submission: 27 February 2026, Villingen-Schwenningen

This page intentionally left blank

Abstract

Fluid 4.0 was conceived as a standardized digitalization framework for industrial hydraulics, enabling machine-readable and vendor-independent descriptions of hydraulic components through the Asset Administration Shell (AAS). While existing Fluid 4.0 submodels primarily focus on identification, documentation, and operational data, they do not explicitly capture the physical and operational relationships required for explainable condition monitoring and predictive maintenance.

This thesis extends Fluid 4.0 by introducing a dedicated submodel for *condition monitoring relationships*, in which degradation mechanisms, operating regimes, and physical constraints are formalized using causal graph structures. The proposed submodel embeds physically grounded knowledge into the AAS, enabling condition states to be represented in a structured and semantically interpretable manner.

The framework is validated through two complementary investigations at component and system level.

At component level, an axial piston pump is analyzed using a normalized degradation coefficient α_{deg} that isolates geometric wear by explicitly accounting for pressure and viscosity influences. Multiple degradation trends are identified under distinct operating states and combined into a physically interpretable health indicator. These relationships are encoded within a causal degradation graph and integrated into the Fluid 4.0 AAS.

At system level, an electro-hydraulic actuator operating under accelerated degradation conditions is investigated. Degradation is interpreted as a progressive transition between statistically inferred operating regimes rather than as an explicitly labeled failure process. Data-driven explainability methods, including SHAP analysis and attention mechanisms, reveal strong dependency on dataset distribution and operating context, highlighting the limitations of purely correlation-based interpretations.

These findings underline the necessity of grounding system-level condition assessment in physically validated component-level representations.

The thesis further proposes a graph-informed formulation for Remaining Useful Life (RUL) estimation that leverages physically interpretable, component-level health indicators as structured state variables. This formulation provides a conceptual basis for structural regularization in predictive modeling while preserving causal traceability.

Overall, this work establishes a scalable foundation for embedding physically grounded, causal, and semantically consistent condition monitoring knowledge into Fluid 4.0-compliant digital twins, enabling more robust and trustworthy predictive maintenance in industrial hydraulic systems.

Kurzfassung

Fluid 4.0 wurde als standardisiertes Digitalisierungsframework für die industrielle Hydraulik konzipiert, das maschinenlesbare und herstellerunabhängige Beschreibungen hydraulischer Komponenten über die Asset Administration Shell (AAS) ermöglicht. Während bestehende Fluid 4.0-Submodelle primär Identifikation, Dokumentation und Betriebsdaten adressieren, erfassen sie die für erklärbares Condition Monitoring und Predictive Maintenance erforderlichen physikalischen und betrieblichen Zusammenhänge bislang nicht explizit.

Diese Arbeit erweitert Fluid 4.0 durch die Einführung eines dedizierten Submodells für *Condition-Monitoring-Beziehungen*, in dem Degradationsmechanismen, Betriebsregime und physikalische Randbedingungen mithilfe kausaler Graphstrukturen formalisiert werden. Das vorgeschlagene Submodell integriert physikalisch fundiertes Wissen in die AAS und ermöglicht eine strukturierte sowie semantisch interpretierbare Repräsentation von Zustandsinformationen.

Das Framework wird durch zwei komplementäre Untersuchungen auf Komponenten- und Systemebene validiert. Auf Komponentenebene wird eine Axialkolbenpumpe mithilfe eines normierten Degradationskoeffizienten α_{deg} analysiert, der geometrischen Verschleiß isoliert, indem Druck- und Viskositätseinflüsse explizit berücksichtigt werden. Mehrere Degradationstrends unter unterschiedlichen Betriebszuständen werden identifiziert und zu einem physikalisch interpretierbaren Health Indicator kombiniert. Diese Beziehungen werden in einem kausalen Degradationsgraphen kodiert und in die Fluid 4.0-AAS integriert.

Auf Systemebene wird ein elektrohydraulischer Aktuator untersucht, der unter beschleunigten Degradationsbedingungen betrieben wird. Degradation wird dabei als progressiver Übergang zwischen statistisch inferierten Betriebsregimen interpretiert und nicht als explizit gelabelter Ausfallprozess. Datengetriebene Explainability-Methoden, einschließlich SHAP-Analysen und Attention-Mechanismen, zeigen eine starke Abhängigkeit von Datensatzverteilung und Betriebskontext und verdeutlichen damit die Grenzen rein korrelationsbasierter Interpretationen. Diese Ergebnisse unterstreichen die Notwendigkeit, die Zustandsbewertung auf Systemebene in physikalisch validierten Repräsentationen auf Komponentenebene zu verankern.

Darüber hinaus schlägt die Arbeit eine graphbasierte Formulierung zur Schätzung der Remaining Useful Life (RUL) vor, die physikalisch interpretierbare, komponentenbasierte Health Indicators als strukturierte Zustandsvariablen nutzt. Diese Formulierung schafft eine konzeptionelle Grundlage für strukturelle Regularisierung in der prädiktiven Modellierung bei gleichzeitiger Wahrung kausaler Nachvollziehbarkeit.

Insgesamt etabliert diese Arbeit eine skalierbare Grundlage zur Einbettung physikalisch fundierten, kausalen und semantisch konsistenten Condition-Monitoring-Wissens in Fluid 4.0-konforme digitale Zwillinge und ermöglicht damit eine robustere und vertrauenswürdigere Predictive Maintenance in industriellen Hydrauliksystemen.

Eidesstattliche Erklärung

Hiermit versichere ich an Eides statt, dass ich die vorliegende Arbeit selbstständig und ohne unzulässige fremde Hilfe angefertigt habe. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder unveröffentlichten Schriften entnommen wurden, sind als solche kenntlich gemacht.

Die Arbeit wurde in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegt und ist bisher nicht veröffentlicht worden.

Ulm, den 20. 02. 2026



Manuel Caipo Ccoa



Para quienes confían en mí.

Acknowledgements

This thesis was conducted in cooperation with Bosch Rexroth AG in the context of my student employment at the company. To protect confidential information, any company-internal data, identifiers, and implementation details have been anonymized or omitted. The presented methods and results are described at a level suitable for public academic dissemination.

This page intentionally left blank

Contents

Acknowledgements	V
Nomenclature	XIII
1 Introduction and Motivation	1
1.1 Industrial Motivation and Context	1
1.1.1 Condition Monitoring Challenges in Fluid Power Systems	1
1.1.2 Specific Characteristics of Hydraulic Systems (p-T- μ Coupling)	2
1.1.3 Limitations of purely data-driven approaches	3
1.2 Fluid 4.0 and Asset Administration Shell	6
1.2.1 Digital twins and semantic interoperability	6
1.2.2 Existing AAS submodels for fluid power systems	7
1.2.3 Missing representation of physical degradation semantics	7
1.3 Problem Statement	7
1.4 Research Questions	9
2 State of the Art	10
2.1 Industry 4.0, Digital Twins, and Asset Administration Shell	10
2.1.1 Industry 4.0: Motivation, Scope, and Research Priorities	10
2.1.2 Asset Administration Shell (AAS) as a Semantic Interoperability Backbone	11
2.1.3 Fluid 4.0	14
2.2 Condition Monitoring in Hydraulic Systems	17
2.2.1 Conventional performance indicators as physically interpretable proxies	17
2.3 Data-Driven and Explainable Artificial Intelligence	19
2.3.1 Machine Learning and Deep Learning Approaches	19
2.3.2 Explainability methods and their limitations	20
2.4 Physics-Informed and Graph-Based Modeling Approaches	22
2.4.1 Graph Neural Networks for RUL Prediction	22
2.4.2 Taxonomy of Graph-Based RUL Modeling	24
2.4.3 Limitations of Purely Data-Driven Graph Models	24
2.4.4 Physics-Informed Graph Representations	25
2.5 Chapter Summary and Research Gap	25
3 Conceptual Framework	27
3.1 Semantic Concepts in Condition Monitoring	27
3.2 Formalization of degradation, anomalies, failures, and errors	28
3.3 Graph families by monitoring objective.	30
3.3.1 Short-Horizon Operational Anomaly Graph	30

3.3.2	Causal Graph Representation of Degradation	32
3.4	Condition Monitoring Relationships Submodel for the AAS	34
3.5	Chapter Summary and Conceptual Outcomes	36
4	Physics-Based Condition Evaluation of Axial Piston Pumps	37
4.1	Motivation and Core Challenge	37
4.2	Pump Under Test and Dataset Description	37
4.2.1	Kinematic Viscosity Approximation	39
4.2.2	Statistical Analysis under Steady-State Kinematic Viscosity Conditions . .	41
4.3	Limitations of Leakage-Based and Volumetric Efficiency Metrics	44
4.4	Fundamental Requirement: Decoupling Degradation from Operating Conditions	45
4.4.1	Degradation Coefficient α_{deg} : Physical Interpretation	45
4.4.2	Physical justification of the leakage degradation parameter α_{deg}	46
4.4.3	Correlation Analysis	47
4.4.4	Alpha Computation and Analysis	49
4.5	From Single Indicators to Graph-Based Health Evaluation	52
4.5.1	Computation of the Graph-Based Health Indicator	52
4.5.2	Graphical Representation of the Health Indicator Computation	54
4.5.3	Review of α_{deg} and Health Indicator Across the Evaluated Days	56
4.5.4	Statistical Analysis of α_{deg} and Volumetric Efficiency	58
4.5.5	Graph Representation of the Degradation Calculation and GNN-Based Modeling Outlook	60
4.6	Chapter Summary	64
5	System-Level Explainability under Limited Observability	65
5.1	Chapter Motivation and Positioning	65
5.2	Industrial Edge Architecture and Event-Centric Fault Integration	66
5.3	Event-Driven RUL Formulation	67
5.4	Data-Driven Explainability and Its Limitations	68
5.5	From Dataset-Dependent Attribution to Physics-Controlled Structural Explainability	70
5.5.1	System-Level Case: Distribution-Dependent Explainability	70
5.5.2	Component-Level Case: Identifiability and Controlled Structural Modeling	71
5.5.3	From Post-Hoc Attribution to Structural Control via Causal Graphs	71
5.5.4	Conceptual Structural Regularization - Component Level Outlook	72
5.5.5	Epistemic Contrast	72
5.6	Chapter Summary and Conceptual Implications	73
6	Discussion	75
7	Conclusion	77
	Bibliography	79